

Projektdokumentation

Explorative Datenanalyse zur Prädiktion von Diabetes mellitus anhand des Pima-Indians-Datensatzes

1. Projektinformation

Name: Stefan Meyer-Wehrmann

Matrikelnummer: 108691

Quellcode: <https://github.com/StefanM-W/Diabetes-Datenanalyse>

2. Kernidee und Datenquelle

Ziel dieses Datenanalyse-Projekts ist es, auf Basis des frei verfügbaren „Pima Indians Diabetes“-Datensatzes (Kaggle) mögliche Zusammenhänge zwischen medizinischen und demographischen Merkmalen und dem Auftreten eines Diabetes mellitus zu untersuchen und daraus eine Vorhersage abzuleiten.

Der Datensatz umfasst 768 Datensätze von Frauen der Pima-Bevölkerung (Arizona, USA) im Alter von über 21 Jahren. Neben der Zielvariable (Outcome: Diabetes ja/nein) enthält er acht Merkmale: die Anzahl der Schwangerschaften (Pregnancies), das Ergebnis des oralen Glukosetoleranztests (Glucose), den Seruminsulinspiegel (Insulin), den diastolischen Blutdruck (BloodPressure), die Hautfaltendicke der Trizepsregion (SkinThickness), den Body-Mass-Index (BMI), das Alter (Age) sowie die Diabetes Pedigree Function, einen statistischen Kennwert, der die familiäre Vorbelastung abbildet.

Im Rahmen der explorativen Datenanalyse sollen sowohl einzelne als auch kombinierte Merkmalsausprägungen im Hinblick auf ihren Zusammenhang mit dem Diabetes-Outcome betrachtet werden. Ziel ist die Identifikation relevanter Einflussfaktoren, die anschließend als Grundlage für eine Vorhersage des Erkrankungsrisikos dienen können.

Die Auswahl des Datensatzes erfolgte aufgrund des Bezuges zu einer der häufigsten chronischen Stoffwechselerkrankungen sowie der Abbildung etablierter sowie klinisch plausibler Risikofaktoren. Zudem bietet die Größe des Datensatzes eine ausreichende Grundlage für eine explorative Analyse ohne dabei unübersichtlich zu werden. Vorhandene Datenqualitätsprobleme bieten realistische Problemkonstellationen, welche während der Exploration gelöst werden müssen. Zudem handelt es sich um einen häufig genutzten Datensatz, sodass ein Abgleich der eigenen Ergebnisse mit publizierten Analysen möglich ist.

3. Datenbereinigung

3.1. Probleme in den Rohdaten

Der Rohdatensatz umfasst 768 Datensätze mit neun Merkmalen. Die zentrale Auffälligkeit bestand darin, dass fehlende Messwerte als „0“ kodiert waren. Für mehrere Merkmale ist ein Wert von 0 physiologisch quasi unmöglich (z. B. Glucose, BloodPressure, BMI) und daher als fehlender Wert zu interpretieren. Betroffen sind fünf Spalten:

Merkmal	Fehlend (n)	Anteil
Insulin	374	48,7 %
SkinThickness	227	29,6 %
BloodPressure	35	4,6 %
BMI	11	1,4 %
Glucose	5	0,7 %

Zu beachten ist, dass eine 0 bei Pregnancies und Outcome ein gültiger bzw. natürlicher Wert ist und daher nicht umkodiert werden muss. Das Merkmal DiabetesPedigreeFunction enthielt keine Nullwerte. Darüber hinaus fanden sich vereinzelt unplausible Extremwerte (sehr niedriger sowie sehr hoher diastolischer Blutdruck und eine Hautfaltendicke von 99 mm). Duplikate waren keine vorhanden.

3.2. Durchgeführte Bereinigungsschritte

Folgende Bereinigungsschritte wurden durchgeführt. Die detaillierte Dokumentation bzw. der entsprechende Code ist in der Cleaning-Pipeline zu finden.

- **Umkodierung der Nullwerte:** Ersetzen der 0-Werte durch „NaN“ in den fünf betroffenen Spalten (unter Ausschluss von Pregnancies und Outcome).
- **Behandlung fehlender Werte:** Auffüllung per Median-Imputation. Wegen der hohen Fehlwertquote bei Insulin und SkinThickness kam ein Löschen von Zeilen (zu starker Datenverlust) oder Spalten (Verlust wichtiger Merkmale) nicht in Frage. Eine positionsbasierte Interpolation wird nach Korrektur nicht verwendet, da die Zeilen keine sinnvolle Reihenfolge besitzen (Querschnittsdaten) und eine lineare Interpolation über den Index inhaltlich nicht begründbar wäre.
- **Duplikatprüfung:** Es waren keine vollständigen Zeilenduplikate vorhanden.
- **Datentypen:** Rückkonvertierung der Messgrößen Glucose, BloodPressure, SkinThickness, Insulin nach der Median-Imputation aufgrund des diskreten Merkmals zum Datentyp int.
- **Ausreißerbehandlung:** Entfernt wurden 6 Zeilen bei BloodPressure und 1 Zeile bei SkinThickness. Bei BloodPressure betraf dies 4 Werte unterhalb der IQR-Untergrenze (< 40 mmHg, medizinischer Notfall, daher am ehesten Messfehler bei Routineerhebung) sowie 2 Werte oberhalb von 110 mmHg (festgelegte Beschränkung auf einen plausiblen Analysebereich). Bei SkinThickness wurde manuell der anatomisch unrealistische Wert von 99 mm entfernt. Ausreißer bei Pregnancies, Insulin, DiabetesPedigreeFunction und Age sowie übrige Werte bei BloodPressure und SkinThickness wurden als valide Werte bewusst beibehalten.
- **Feature Engineering:** Ableitung einer ordinalen Klassifikation (Adipositas Grad 1-3, Präadipositas sowie Normal- und Untergewicht) aus dem BMI zur vereinfachten Auswertung.

3.3. Verbleibende Datensätze

Nach der Bereinigung verbleiben 761 von 768 Datensätzen. Es wurden insgesamt 7 Zeilen im Rahmen der Ausreißerbehandlung entfernt, was einer Retention-Rate von 99,09 % entspricht. Es wurde keine Spalte gelöscht. Durch das Feature Engineering erhöhte sich die Spaltenzahl durch das neue Merkmal Adipositas von 9 auf 10. Einschränkend ist zu berücksichtigen, dass der hohe Anteil imputierter Werte (insbesondere bei Insulin und SkinThickness) die Verteilung dieser Merkmale glättet und dies daher bei der Interpretation der weiteren Analysen zu beachten ist.

4. Datenvisualisierung

Folgende Visualisierungen wurden erstellt:

- Histogramm der Altersverteilung zur Übersicht der Stichprobe
- Balkendiagramm und Kreisdiagramm der Zielvariable (absolute Häufigkeiten und prozentuale Anteile von Diabetes vs. kein Diabetes)
- Histogramme und Boxplots der Glukose (gesamt und getrennt nach Outcome)
- Horizontale Balkendiagramme der Adipositas-Kategorien (Häufigkeit je Kategorie und bezogen auf den Outcome)
- Streudiagramm Glukose vs. BMI, nach Outcome eingefärbt
- Heatmap der Korrelationsmatrix aller numerischen Merkmale
- Interaktives Streudiagramm zu Schwangerschaften vs. Glukose nach Outcome

4.1. Besonders geeignet Visualisierungen

Als besonders aussagekräftig erwiesen sich die nach dem Outcome getrennten Darstellungen (Glukose-Histogramme, Boxplots sowie das eingefärbte Streudiagramm). Diese machen die Unterschiede zwischen erkrankten und gesunden Patientinnen unmittelbar sichtbar. Die Heatmap erwies sich als besonders geeignet, da sie sämtliche paarweisen Zusammenhänge sowie die stärksten Prädiktoren auf einen Blick erkennbar macht. Ebenfalls aussagekräftig ist das Säulendiagramm der Diabetes-Rate je Adipositas-Kategorie, da es die Daten in eine klinisch direkt interpretierbare Kennzahl (Prävalenz je Gewichtsklasse) überführt.

4.2. Gewonnene Erkenntnisse

Die Serum-Glukose ist mit Abstand der stärkste Prädiktor (ca. 0,49; ca. 142 vs. Ca. 111 mg/dL), gefolgt von BMI/Adipositas (ca. 0,31) und Alter (ca. 0,23), wobei auch eine höhere Zahl an Schwangerschaften mit einem erhöhten Diabetes-Risiko einhergeht. Der diastolische Blutdruck ist dagegen kein tragfähiges Unterscheidungsmerkmal (ca. 0,17). Als Einschränkung ist der mit ca. 35 % Erkrankten unbalancierte Datensatz zu berücksichtigen.

5. Machine Learning

Da nur zwischen zwei Ausprägungen (Diabetes ja/nein) unterschieden wird, handelt es sich um eine binäre Klassifikation.

Als Ausgangsmodell diente ein Entscheidungsbaum (Decision Tree). Darauf aufbauend wurden mehrere Varianten erprobt, um die Vorhersage zu verbessern: die Ergänzung zusätzlicher Merkmale (z.B. Missing Value Indicator, Interaktions-Features oder Risiko-Scores), eine

automatisierte Suche nach den besten Modelleinstellungen (GridSearchCV) sowie mit dem Random Forest ein Verfahren, das mehrere Entscheidungsbäume kombiniert. Der Datensatz wurde zuvor im Verhältnis 80/20 in Trainings- und Testdaten aufgeteilt.

Zur Bewertung wurde neben der Trefferquote (Accuracy) vor allem berücksichtigt, wie zuverlässig tatsächlich erkrankte Patientinnen erkannt werden (F1-Score). Dies ist wichtig, da der Datensatz unausgeglichen ist und die reine Trefferquote allein ein zu optimistisches Bild ergäbe.

Insgesamt erreichten die Modelle eine Trefferquote von rund 78 % (F1 ca. 0,70). Die zusätzlichen Erweiterungen und die aufwendigere Optimierung brachten dabei tendenziell eine Verschlechterung der Trefferquote. Insbesondere durch Interaktions-Features oder einen Risiko-Score bzw. durch das Hyperparameter Tuning des Baseline-Models ließ sich keine relevante Verbesserung erzielen. Einschränkend ist zu berücksichtigen, dass die Vorhersagegüte insgesamt moderat bleibt und insbesondere die falsch-negativen Fälle im medizinischen Kontext kritisch zu bewerten sind.

6. Streamlit-Anwendung

Auf Basis der bereinigten Daten und des trainierten Modells wurde eine interaktive Streamlit-Anwendung entwickelt, die alle bisherigen Analyseschritte in einem Dashboard bündelt. Über eine Sidebar-Navigation gliedert sich die Anwendung in vier Bereiche: Übersicht, Daten, Visualisierungen und Prognose.

6.1. Funktionalitäten und interaktive Elemente

- Übersicht: Kennzahlen zum Datensatz (Anzahl Patientinnen, Anzahl Features) sowie eine Vorschau- und Statistiktabelle
- Daten (Feature Explorer): Dropdown-Menü (Selectbox) zur Auswahl eines von acht numerischen Merkmalen, dazu Kennzahlen (Durchschnitt, Median) sowie ein entsprechendes dynamisch erstelltes Histogramm
- Visualisierungen: Auswahl zwischen fünf vorbereiteten Abbildungen (u. a. Zielvariable, BMI vs. Alter, Glukose nach Outcome, Adipositas-Kategorien, Glukose vs. BMI)
- Prognose: Prognose anhand des Baseline-Models sowie freie Auswahl der Prognose-Parameter mit entsprechenden Eingabe-Felder für die gewählten Parameter (inklusive Mittelung der fehlenden Parameter). Zusätzlich Möglichkeit des CSV-Uploads und Berechnung einer Prognose anhand der enthaltenen Daten pro Zeile.

6.2. Screenshots




Abbildung 1: Bereich „Daten“ – über das Dropdown-Menü links wird das Merkmal ausgewählt, die App zeigt automatisch Durchschnitt, Median und ein Histogramm der Verteilung.

The screenshot displays the 'Diabetes-Prognose' interface. On the left, a sidebar contains a 'Navigation' menu with options: 'Übersicht', 'Daten', 'Visualisierungen', and 'Prognose' (selected). Below this is a section 'Eingabe auswählen' with a question 'Womit soll die Prognose erstellt werden?' and two radio buttons: 'Alle Parameter' and 'Nur ausgewählte Parameter' (selected). Below this is a section 'Parameter auswählen' with a question 'Welche Patientendaten sollen für die Prognose genutzt werden?' and a list of parameters: 'Glukose (mg/dL)', 'Schwangerschaften', 'BMI (kg/m²)', and 'Alter' (all selected). The main content area is titled 'Diabetes-Prognose' and shows a blue box with text: 'Es rechnet weiterhin das Modell aus dem ML-Notebook. Angegeben werden 4 von 8 Parametern: Glukose (mg/dL), Schwangerschaften, BMI (kg/m²), Alter. Über die übrigen Merkmale wird gemittelt.' Below this is a form to input patient data: 'Gib die Patientendaten ein:' with input fields for 'Glukose (mg/dL)' (120), 'Schwangerschaften' (3), 'BMI (kg/m²)' (32.00), and 'Alter' (60). A red button labeled 'Vorhersage' is below the form. The results section, titled 'Ergebnis:', shows a red box with text: 'Risiko für Diabetes! (Wahrscheinlichkeit: 52.1%)'. Below this is a bar chart showing the probability of 'Kein Diabetes' (47.9%) and 'Diabetes' (52.1%).

Abbildung 2: Bereich „Prognose“ – in der Parameterauswahl in der Sidebar wurden vier Merkmale ausgewählt (Glukose (mg/dL), Schwangerschaften, BMI (kg/m²), Alter), nach Eingabe der Werte liefert das trainierte Modell ein Outcome inklusive Wahrscheinlichkeit